MODUL PRAKTIKUM 5: Exploratory Data Analysis Lanjutan (Agregasi & Analisis Multivariat)

A. Tujuan Praktikum

1. Mahasiswa mampu melakukan agregasi data (pengelompokan) menggunakan fungsi `groupby`.
2. Mahasiswa mampu membuat **Pivot Table** di Pandas layaknya di Microsoft Excel.
3. Mahasiswa mampu melakukan analisis multivariat dan mendeteksi *outlier* dalam dua dimensi menggunakan **Scatter Plot**.
4. Mahasiswa mampu mengukur dan memvisualisasikan korelasi antar variabel angka menggunakan **Heatmap**.

B. Persiapan Lingkungan Kerja

Pada pertemuan ini, pastikan *library* analisis dan visualisasi sudah siap. Buka Terminal / Command Prompt dan jalankan:

```
pip install pandas matplotlib seaborn
```

C. BAGIAN 1: Agregasi Data dengan Groupby

Di industri, kita sering diminta merangkum data berukuran besar menjadi laporan singkat (misal: "Berapa rata-rata gaji per departemen?"). Untuk ini, kita menggunakan fungsi `groupby`.

Praktik 1: Menghitung Rata-rata Gaji per Departemen

```
import pandas as pd

# 1. Membuat Dataset Karyawan
data = {
    'Nama': ['Andi', 'Budi', 'Citra', 'Diana', 'Eka', 'Fajar'],
    'Departemen': ['IT', 'HR', 'IT', 'Finance', 'HR', 'IT'],
    'Gender': ['L', 'L', 'P', 'P', 'L', 'L'],
    'Pengalaman_Thn': [2, 5, 3, 10, 1, 8],
    'Gaji_Juta': [6.0, 7.5, 7.0, 15.0, 4.5, 12.0]
}
df = pd.DataFrame(data)

# 2. Menggunakan Groupby untuk agregasi
print("--- Rata-rata Gaji per Departemen ---")
# Dikelompokkan berdasarkan 'Departemen', lalu dihitung rata-rata (.mean) 'Gaji_Juta
rata_gaji = df.groupby('Departemen')['Gaji_Juta'].mean()
print(rata_gaji)

# 3. Menghitung jumlah karyawan per departemen
print("\n--- Jumlah Karyawan per Departemen ---")
jumlah_karyawan = df.groupby('Departemen')['Nama'].count()
print(jumlah_karyawan)
```

D. BAGIAN 2: Tabulasi Silang dengan Pivot Table

Pivot Table adalah versi *upgrade* dari `groupby`. Pivot Table memungkinkan kita memecah data berdasarkan **dua kategori sekaligus** (misal: Departemen pada baris, Gender pada kolom).

Praktik 2: Membuat Pivot Table Karyawan

```
# Membuat Pivot Table
# values = Kolom yang mau dihitung angkanya
# index = Kategori untuk baris (ke bawah)
# columns = Kategori untuk kolom (ke samping)
# aggfunc = Fungsi perhitungannya (mean, sum, count, dll)

tabel_pivot = pd.pivot_table(
    df,
    values='Gaji_Juta',
    index='Departemen',
    columns='Gender',
    aggfunc='mean',
    fill_value=0 # Mengisi nilai kosong/NaN dengan angka 0
)

print("--- Pivot Table Rata-rata Gaji (Departemen vs Gender) ---")
print(tabel_pivot)
```

E. BAGIAN 3: Analisis Multivariat & Deteksi Outlier (Scatter Plot)

Jika *Boxplot* (di Pertemuan 4) melihat sebaran pada *satu* variabel saja, **Scatter Plot** digunakan untuk membandingkan **dua variabel numerik** sekaligus (analisis bivariat/multivariat) dan mendeteksi *outlier* dari pola hubungannya.

Praktik 3: Hubungan Pengalaman Kerja vs Gaji

```
import matplotlib.pyplot as plt
import seaborn as sns

plt.figure(figsize=(8, 5))

# Membuat Scatter Plot
# x = sumbu horizontal, y = sumbu vertikal
# hue = memberi warna berbeda berdasarkan kategori departemen
sns.scatterplot(
    data=df,
    x='Pengalaman_Thn',
    y='Gaji_Juta',
    hue='Departemen',
    s=100 # s adalah ukuran (size) titik
)

plt.title("Hubungan Pengalaman Kerja dan Gaji Karyawan")
plt.xlabel("Pengalaman (Tahun)")
plt.ylabel("Gaji (Juta Rupiah)")
plt.grid(True, linestyle='--', alpha=0.6) # Menambah garis bantu

plt.show()
```

G. TUGAS MANDIRI (Analisis Dataset Properti/Perumahan)

Ketikkan *dataset* harga rumah berikut ini ke dalam program Python Anda:

```
import pandas as pd

data_rumah = {
    'Lokasi': ['Pusat', 'Pinggiran', 'Pusat', 'Pusat', 'Pinggiran', 'Pusat', 'Pinggiran', 'Pinggiran'],
    'Tipe': ['Minimalis', 'Mewah', 'Mewah', 'Minimalis', 'Minimalis', 'Mewah', 'Mewah', 'Minimalis'],
    'Luas_Tanah': [120, 300, 250, 100, 90, 400, 280, 85],
    'Harga_Milyar': [1.5, 3.2, 4.0, 1.2, 0.8, 10.5, 2.9, 0.7]
}
df_rumah = pd.DataFrame(data_rumah)
```

Instruksi Pengerjaan:

1. **(Skor 30) Groupby & Pivot:**
    - Hitung total nilai aset (jumlah `Harga_Milyar`) per `Lokasi` menggunakan `groupby`.
    - Buatlah Pivot Table untuk melihat rata-rata `Harga_Milyar` dengan `Lokasi` sebagai baris (*index*) dan `Tipe` sebagai kolom (*columns*).
2. **(Skor 35) Scatter Plot (Multivariat):** Buat grafik *Scatter Plot* menggunakan Seaborn untuk melihat hubungan antara `Luas_Tanah` (sumbu x) dan `Harga_Milyar` (sumbu y). Beri pembeda warna (`hue`) berdasarkan `Tipe`. Dari grafik tersebut, deteksi apakah terdapat satu rumah yang harganya sangat tidak wajar (pencilan/*outlier*)!
3. **(Skor 35) Heatmap Korelasi:** Hitung matriks korelasi hanya pada kolom numerik (`Luas_Tanah` dan `Harga_Milyar`), lalu tampilkan grafiknya menggunakan *Heatmap* dengan angka tercetak di dalam kotak (`annot=True`).

Notes Notes

1. Fokus Pengamatan (Satu vs Banyak Kolom):

- **Pertemuan 4:** Hanya melihat satu kolom berdiri sendiri. Misalnya, melihat grafik sebaran "Gaji" saja (Histogram), atau menghitung jumlah orang di kolom "Departemen" saja (Bar Chart).
- **Pertemuan 5:** Melihat korelasi dua kolom atau lebih sekaligus. Misalnya, membuktikan secara visual apakah "Lama Pengalaman Kerja" benar-benar mempengaruhi besaran "Gaji" menggunakan grafik *Scatter Plot* dan *Heatmap*.

2. Sudut Pandang Mendeteksi Outlier:

- **Pertemuan 4 (Boxplot):** Mendeteksi outlier dari *satu* sisi. Contoh: "Gaji 25 juta ini aneh karena mayoritas cuma 5 juta."
- **Pertemuan 5 (Scatter Plot):** Mendeteksi outlier dari *dua* sisi sebab-akibat. Contoh: "Gaji 25 juta mungkin wajar jika pengalamannya 20 tahun. Tapi di grafik ini, ada titik orang bergaji 25 juta padahal pengalamannya baru 1 tahun. Ini pasti data error/outlier!"

3. Agregasi (Rekap Laporan):

- **Pertemuan 4:** Belum ada proses meringkas tabel data.
- **Pertemuan 5:** Mahasiswa diajarkan fungsi `groupby` dan `pivot_table`. Ini adalah *skill* wajib dunia kerja untuk merangkum ribuan baris data mentah menjadi satu tabel laporan kecil yang rapi (misalnya tabel rata-rata gaji karyawan pria vs wanita per departemen).

4. Jenis Visualisasi yang Digunakan:

- **Pertemuan 4:** *Bar Chart*, *Histogram*, dan *Boxplot*.
- **Pertemuan 5:** *Scatter Plot* (grafik titik-titik kordinat X dan Y) dan *Heatmap* (kotak warna-warni bersuhu untuk melihat skor korelasi antar angka).